

D'OpenAI à Opensource AI

Naviguer entre propriété commerciale et ouverture collaborative

Raphaël Semeteys

WORLDLINE

19 Décembre 2024

Normandie.ai

Raphaël Semeteys

Head of DevRel
Architecte sénior, Expert Open Source

- **Worldline** depuis 1999
- Basé à Paris
- Yogeek
- raphiki.github.io



@RaphaelSemeteys

dev.to/raphiki/

linkedin.com/in/raphaelsemeteys/

WORLDLINE

Normandie.ai

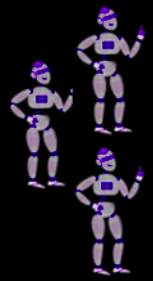
Les premiers jours des LLMs

Des modèles statistiques simples aux LLMs









2010's

Word embeddings
Word2Vec, GloVe

2017-2018

"*Attention is All You Need*"
Transformers

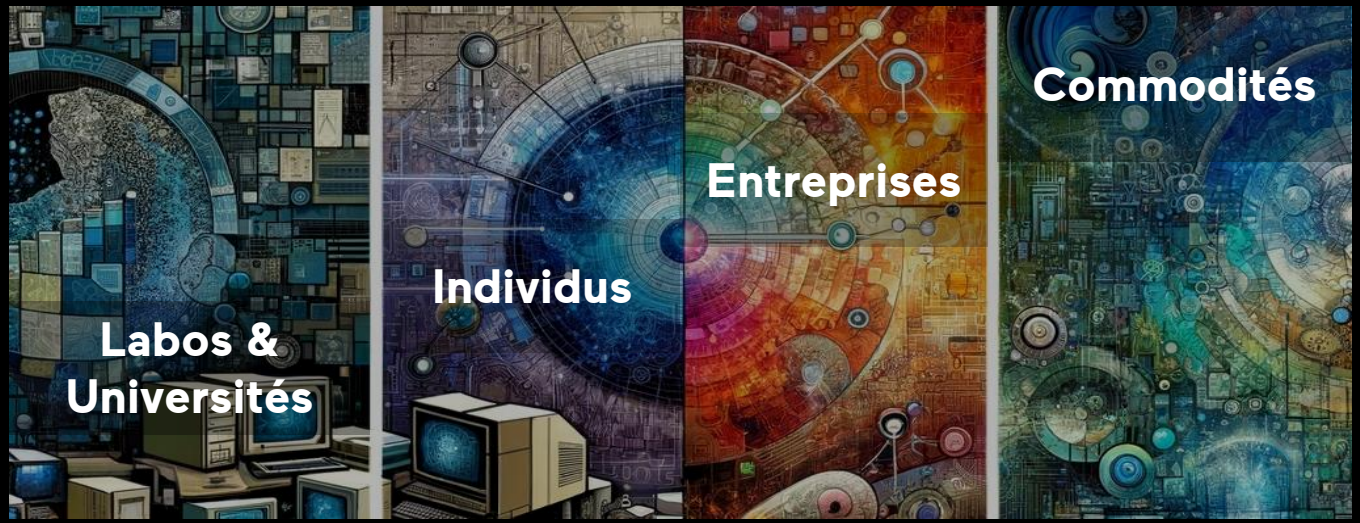
2020's

GenAI, ChatGPT
Responsabilité

Demain ?

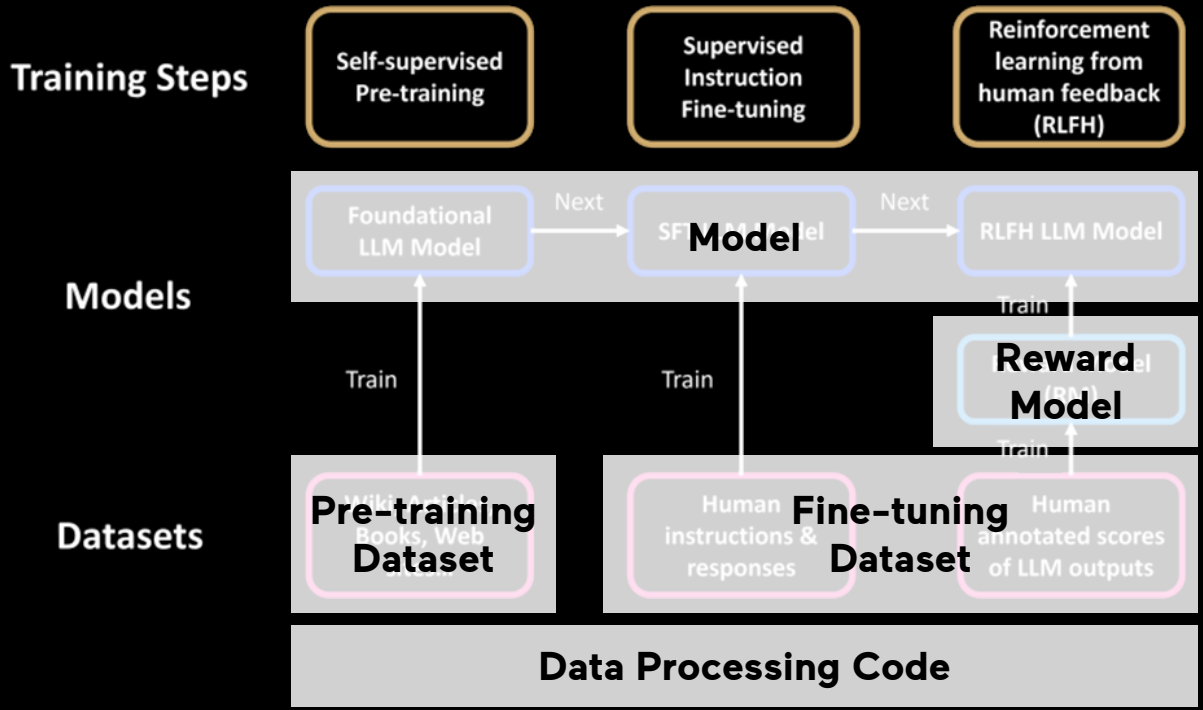
Small Language Models
Mobile, Agents et LAMs

La GenAI traverse son moment Linux



- Tout comme l'open source (et Internet), mais beaucoup plus rapidement !
- Dynamique entre ouverture collaborative et propriété commerciale
- Besoin de clarté sur les licences

Définir l'ouverture d'un modèle



Définir l'ouverture d'un modèle

Score	Niveau	Description	Model (poids)	Pre-training Dataset	Fine-tuning Dataset	Reward model	Data Processing Code
0	**Fermé**	**Aucun accès** à des informations publiques, données ou actifs					
1	**Recherche publiée**	**Articles de recherche publiés** mais sans plus d'informations, de données ou d'actifs					
2	**Accès restreint**	Accès possible uniquement avec **accord spécial** (commercial, recherche...)					
3	**Ouvert avec limitations**	Accès et réutilisation possibles mais avec certaines **limitations d'utilisation**					
4	**Totalement open**	Accès et réutilisation possibles **sans restriction d'utilisation** (ex. licence open source)					

Leader du marché : OpenAI

Écart par rapport à la vision originale de transparence et de recherche



GPT-1 & 2

Non lucratif (US)		
Composant	**Score**	**Niveau**
Model	4	Totalement ouvert
Dataset	1	Recherche publiée
Code	1	Recherche publiée

→

GPT-3.x & 4.x/o

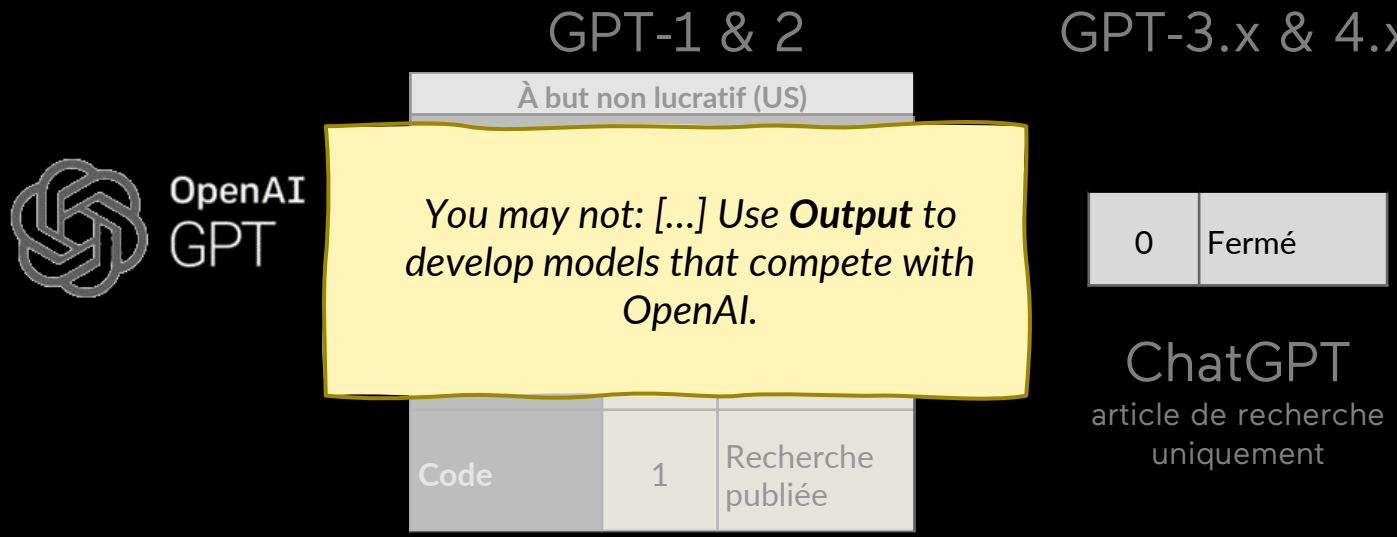
0	Fermé

ChatGPT

article de recherche uniquement

Leader du marché : OpenAI

Écart par rapport à la vision originale de transparence et de recherche



Interdiction d'entrainer des LLMs commerciaux

Leader du marché : Google

De la recherche ouverte à une approche pragmatique



Entreprise (US)		
Composant	Score	Niveau
Model	4	Totalement ouvert
Dataset	2	Accès restreint
Code	4	Totalement ouvert

→



1	Recherche publiée
1	Recherche publiée
0	Fermé

↔



3	Ouvert avec limitations
1	Recherche publiée
4	Toolchain disponible

Leader du marché : Google

De la recherche ouverte à une approche pragmatique

Google BERT

PaLM 2

Gemma

Composant		
Model		
Dataset		
Code	4	Totalement ouvert

0	Fermé

3	Ouvert avec limitations
1	Recherche publiée
4	Toolchain disponible

*You may **not use nor allow others to use** Gemma or Model Derivatives to: [illegals activities, unlicensed practices of profession, abuse, security bypass and promotion of hatred, abuse, violence, monitoring people without consent, misinformation/defamation, automate decisions concerning human rights and well-being, etc.]*

L'IA responsable contredit la définition de l'open source

Autres acteurs majeurs

Rattrapent leur retard dans la ruée vers l'or de la GenAI

Créent leurs propres modèles (ouverts)













S'associent pour l'infrastructure (inférence et entrainement)

Leader du marché : Meta

Voyage vers l'ouverture

RoBERTa

Entreprise (US)		
Composant	Score	Niveau
Model	4	Totalement ouvert
Dataset	3	Ouvert avec limitations
Code	4	Totalement ouvert

LLaMA by Meta

3	Ouvert avec limitations
1	Recherche publiée
1	Recherche publiée

Leader du marché : Meta

Voyage vers l'ouverture

RoBERTa

LLaMA

Additional Commercial Terms. *If, on the Llama 2 version release date, the monthly active users of the products or services made available by or for Licensee, or Licensee's affiliates, is greater than 700 million monthly active users in the preceding calendar month, you must request a license from Meta, which Meta may grant to you in its sole discretion, and you are not authorized to exercise any of the rights under this Agreement unless or until Meta otherwise expressly grants you such rights.*



Restriction à l'utilisation
licence pour les plateformes de plus de 700 M d'utilisateurs

Leader du marché : Meta

Voyage vers l'ouverture

RoBERTa

LLaMA

***Redistribution and Use**. If you distribute or make available the Llama Materials (or any derivative works thereof), or a product or service that uses any of them, including another AI model, you shall (A) provide a copy of this Agreement with any such Llama Materials; and (B) prominently display "Built with Meta Llama 3" on a related website, user interface, blogpost, about page, or product documentation.* If you use the Llama Materials to create, train, fine tune, or otherwise improve an AI model, *which is distributed or made available, you shall also include "Llama 3" at the beginning of any such AI model name.*



LLaMA 3 est désormais **plus restrictif** en matière de redistribution et de réutilisation

Progeniture de Llama 2 : Alpaca et Vicuna

Modèles dérivés de Llama 2 par des universités





Recherche (US)		
Composant	Score	Niveau
Model	3	Ouvert avec limitations
Pre-training Dataset	1	Recherche publiée
Fine-tuning Dataset	2	Recherche uniquement
Code	4	Licence Apache 2



Restrictions **héritées** de Llama 2 **et** OpenAI (ShareGPT)

LLMs fondamentaux collaboratifs

	EleutherAI			BLOOM				MISTRAL AI_	
	Non lucratif (US)		Recherche (UAE)		Recherche (EU)		Recherche (US)		Entreprise (FR)	
	EleutherAI GPT-J		Falcon		BLOOM		OpenLLaMa		Mistral	
Model	4	Accès et dérivation sans restriction	3	Ouvert avec limitations	3	Licence Open RAIL	4	Accès et dérivation sans restriction	4	Accès et dérivation sans restriction
Dataset	3	Ouvert avec limitations	4	Accès et dérivation sans restriction	3	Ouvert avec limitations	4	Accès et dérivation sans restriction	0	Pas d'accès ou info publiques
Code	4	Totalement ouvert	1	Instructions générales	4	Totalement ouvert	1	Exemples uniquement	4	Totalement ouvert

Flou sur les **datasets**: *se référer à la licence spécifique du sous-ensemble utilisé*
Notion d'usage **responsable**

LLMs fondamentaux collaboratifs

	Non lucratif (US)	Recherche (UAE)	Recherche (EU)	Recherche (US)	Entreprise (FR)
	EleutherAI GPT-J	Falcon	BLOOM	OpenLLaMa	Mistral
Model					
Dataset					
Code	4 ouvert	1 générales	4 ouvert	1 uniquement	4 ouvert

This license is, in part, based on the Apache License Version 2.0, with a series of modifications. The contribution of the Apache License 2.0 to the framing of this document is acknowledged. ***Please read this license carefully****, as it is different to other 'open access' licenses you may have encountered previously. Use of Falcon180B for hosted services may require a separate license.*

Licences open source **modifiées**

Mistral : IA cuisinée à la française

Surfe les vagues ouvertes et fermées

Mélange de modèles

- Mistral 7B (texte), Pixtral 12B (multimodal), ministraux
- Mixture-of-Experts (SMoE) : Mixtral 8x7B, 8x22B
- Modèles fondamentaux et dérivés (ex. Mathstral)



Mélange de *Business Models* et de licences

- Modèles “Open Source”, SDK *mistral-finetune*
- Modèles commerciaux et optimisés: Small, Large & Embed
- *Sustainable openness* : licence hors-production pour *codestral*



Community VS Enterprise (comme dans l’open source)

Mistral : IA cuisinée à la française

Surfe les vagues ouvertes et fermées

MISTRAL AI_

Mélange de modèles

MNPL - 3.2. Usage Limitation

- You shall only use the Mistral Models and Derivatives (whether or not created by Mistral AI) for testing, research, Personal, or evaluation purposes in Non-Production Environments;

- Subject to the foregoing, You shall not supply the Mistral Models or Derivatives in the course of a commercial activity, whether in return for payment or free of charge, in any medium or form, including but not limited to through a hosted or managed service (e.g. SaaS, cloud instances, etc.), or behind a software layer.



Sustainable openness : licence hors-production pour codestral



Revisite l'ouverture à l'ère du **Cloud** (comme l'open source)

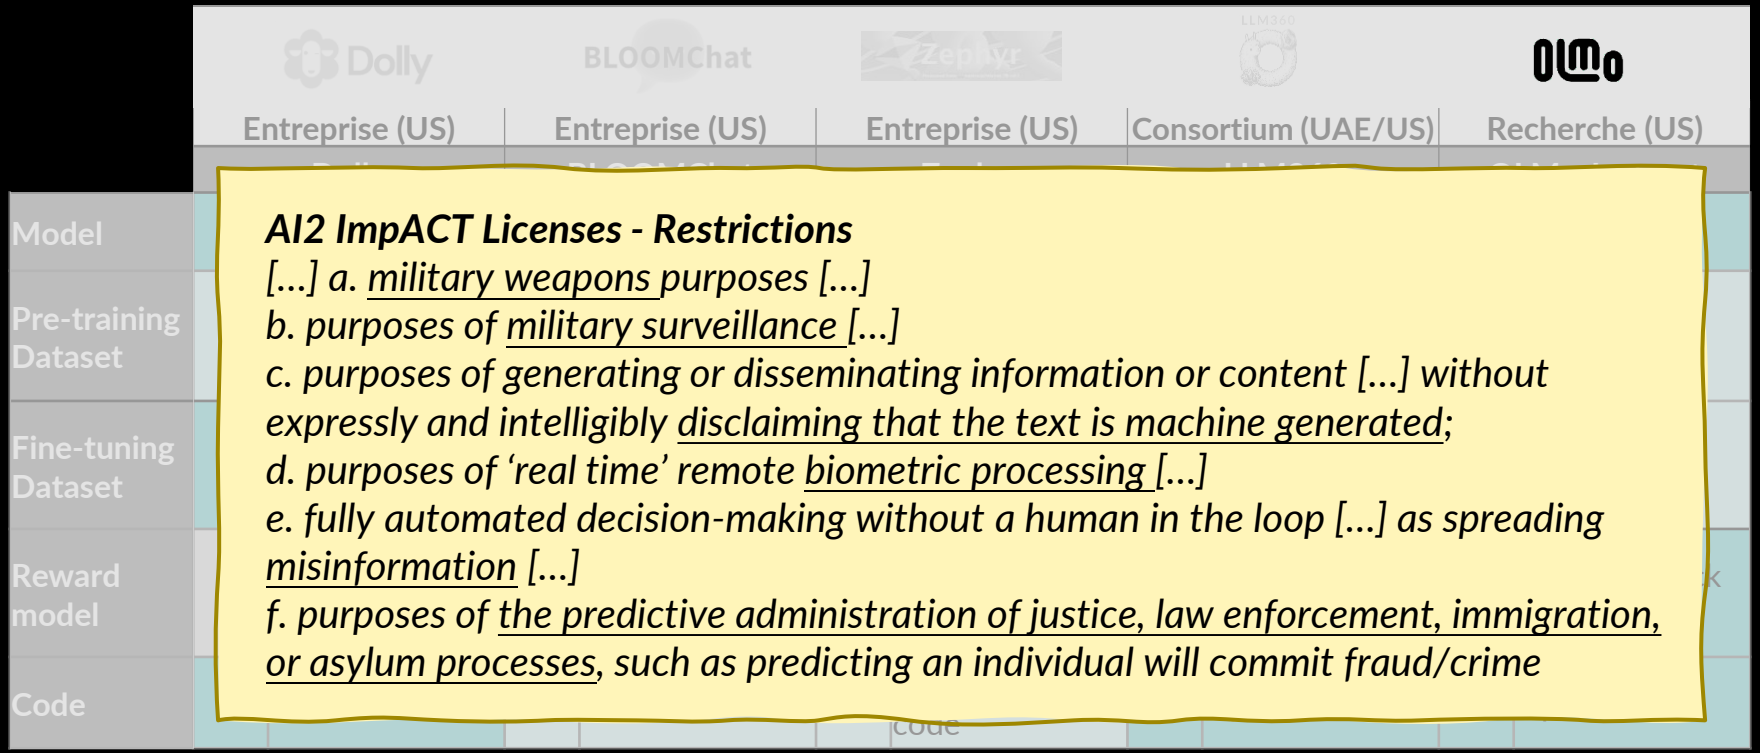
LLMs dérivés collaboratifs

	Dolly		BLOOMChat		Zephyr		LLM360		OLMo	
	Entreprise (US)		Entreprise (US)		Entreprise (US)		Consortium (UAE/US)		Recherche (US)	
	Dolly		BLOOMChat		Zephyr		LLM360		OLMo-Instruct	
Model	4	Basé sur GPT-J	3	Basé sur BLOOM	4	Basé sur Mistral	4	Open source	4	Open source
Pre-training Dataset	3	Basé sur GPT-J	3	Basé sur BLOOM	0	Basé sur Mistral	4	RedPajama, Falcon, StarCoder	3	Dolma (ImpACT MR)
Fine-tuning Dataset	4	Accès et dérivation sans restriction	4	Dolly et LAION	2	Recherche uniquement (OpenAI)	2	Recherche uniquement (OpenAI)	3	Tülu 2 (IMPACT LR)
Reward model	0	Aucun information publique	0	Aucun information publique	3	Recherche et exemples de code	0	Aucun information publique	4	UltraFeedback (MIT)
Code	4	Open source	3	OpenRAIL	3	Exemples de code	4	Open source	4	Open source



Impact des modèles fondamentaux et des datasets

LLMs dérivés collaboratifs



L'IA responsable contredit la définition de l'open source

Autres aspects du moment Linux de la GenAI

Démocratiser/décentraliser l'innovation

Outils collaboratifs et écosystèmes





Notebooks
Communautés
Nouveaux *Business Models*

Optimisation matérielle





Puces AI
Quantization
Décentralisation

Outils et frameworks open source







Ne pas réinventer la roue
Standards interopérables
Au-delà de Python



- **APIs fermées → Open Weights → Free AI** (comme dans *freedom*)
  - Datasets et transitivité en amont
  - Clauses de concurrence
  - Restrictions liées à l'IA responsable
- **Recherche ouverte → Marché concurrentiel → Écosystème coopétitif**
  - L'ouverture favorise la réutilisation et la collaboration
  - La collaboration entraîne la commoditisation et l'innovation

Tout comme l'Open Source !



Initiatives d'évaluation de l'ouverture des LLMS



open source initiative®

The Open Source AI Definition – 1.0

THE LINUX FOUNDATION

MODEL OPENNESS FRAMEWORK



Center for Research on Foundation Models

The Foundation Model Transparency Index



GOUVERNEMENT

Liberté
Égalité
Fraternité

Comparateur d'ouverture de modèles d'IAG