
DEVOXX FRANCE 2025
D’OpenAI à Opensource AI
entre propriété commerciale
et ouverture collaborative
WORLDLINE

Raphaël Semeteys

WORLDLINE



- Head of DevRel
- Architecte sénior
- Expert Open Source

- Worldline depuis 1999
- Basé à Paris



- raphiki.github.io
- Podcast Projets Libres !

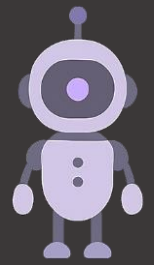

Entrons dans
la jungle des LLMs…

Des modèles statistiques simples aux LLMs



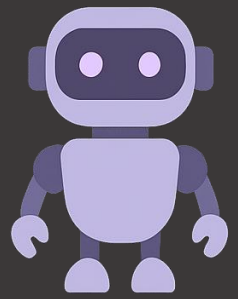
2010’s

Word embeddings
Word2Vec, GloVe



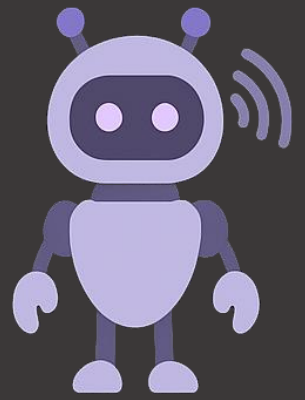
2017-2018

“*Attention is All You Need*"
Transformers



2020’s

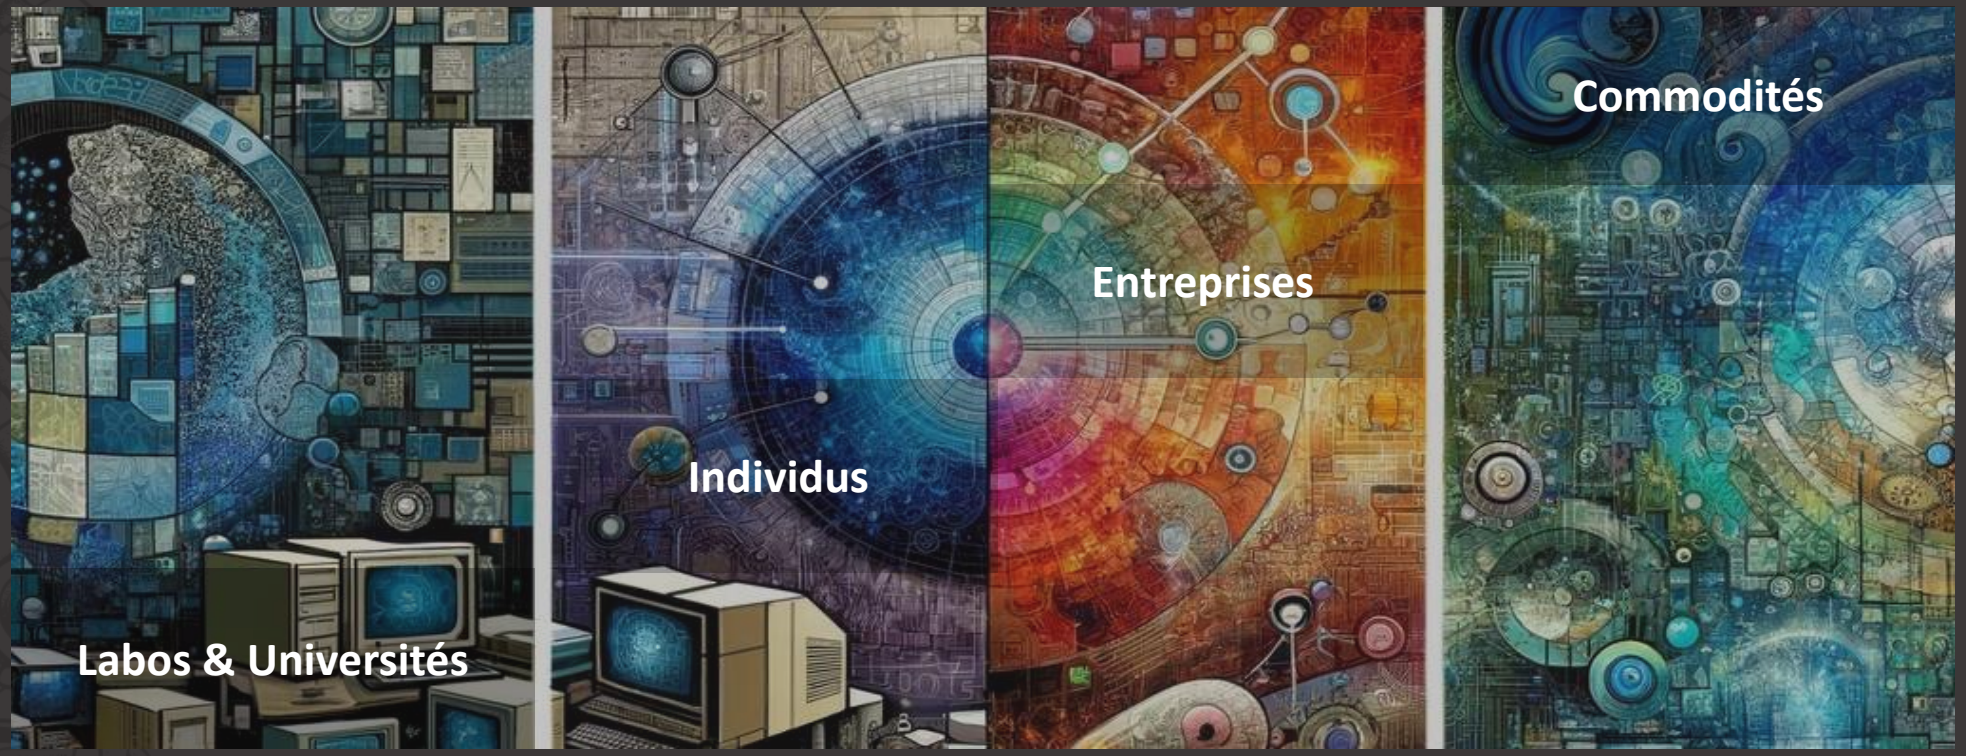
ChatGPT, Multimodal
Responsabilité



Demain ?

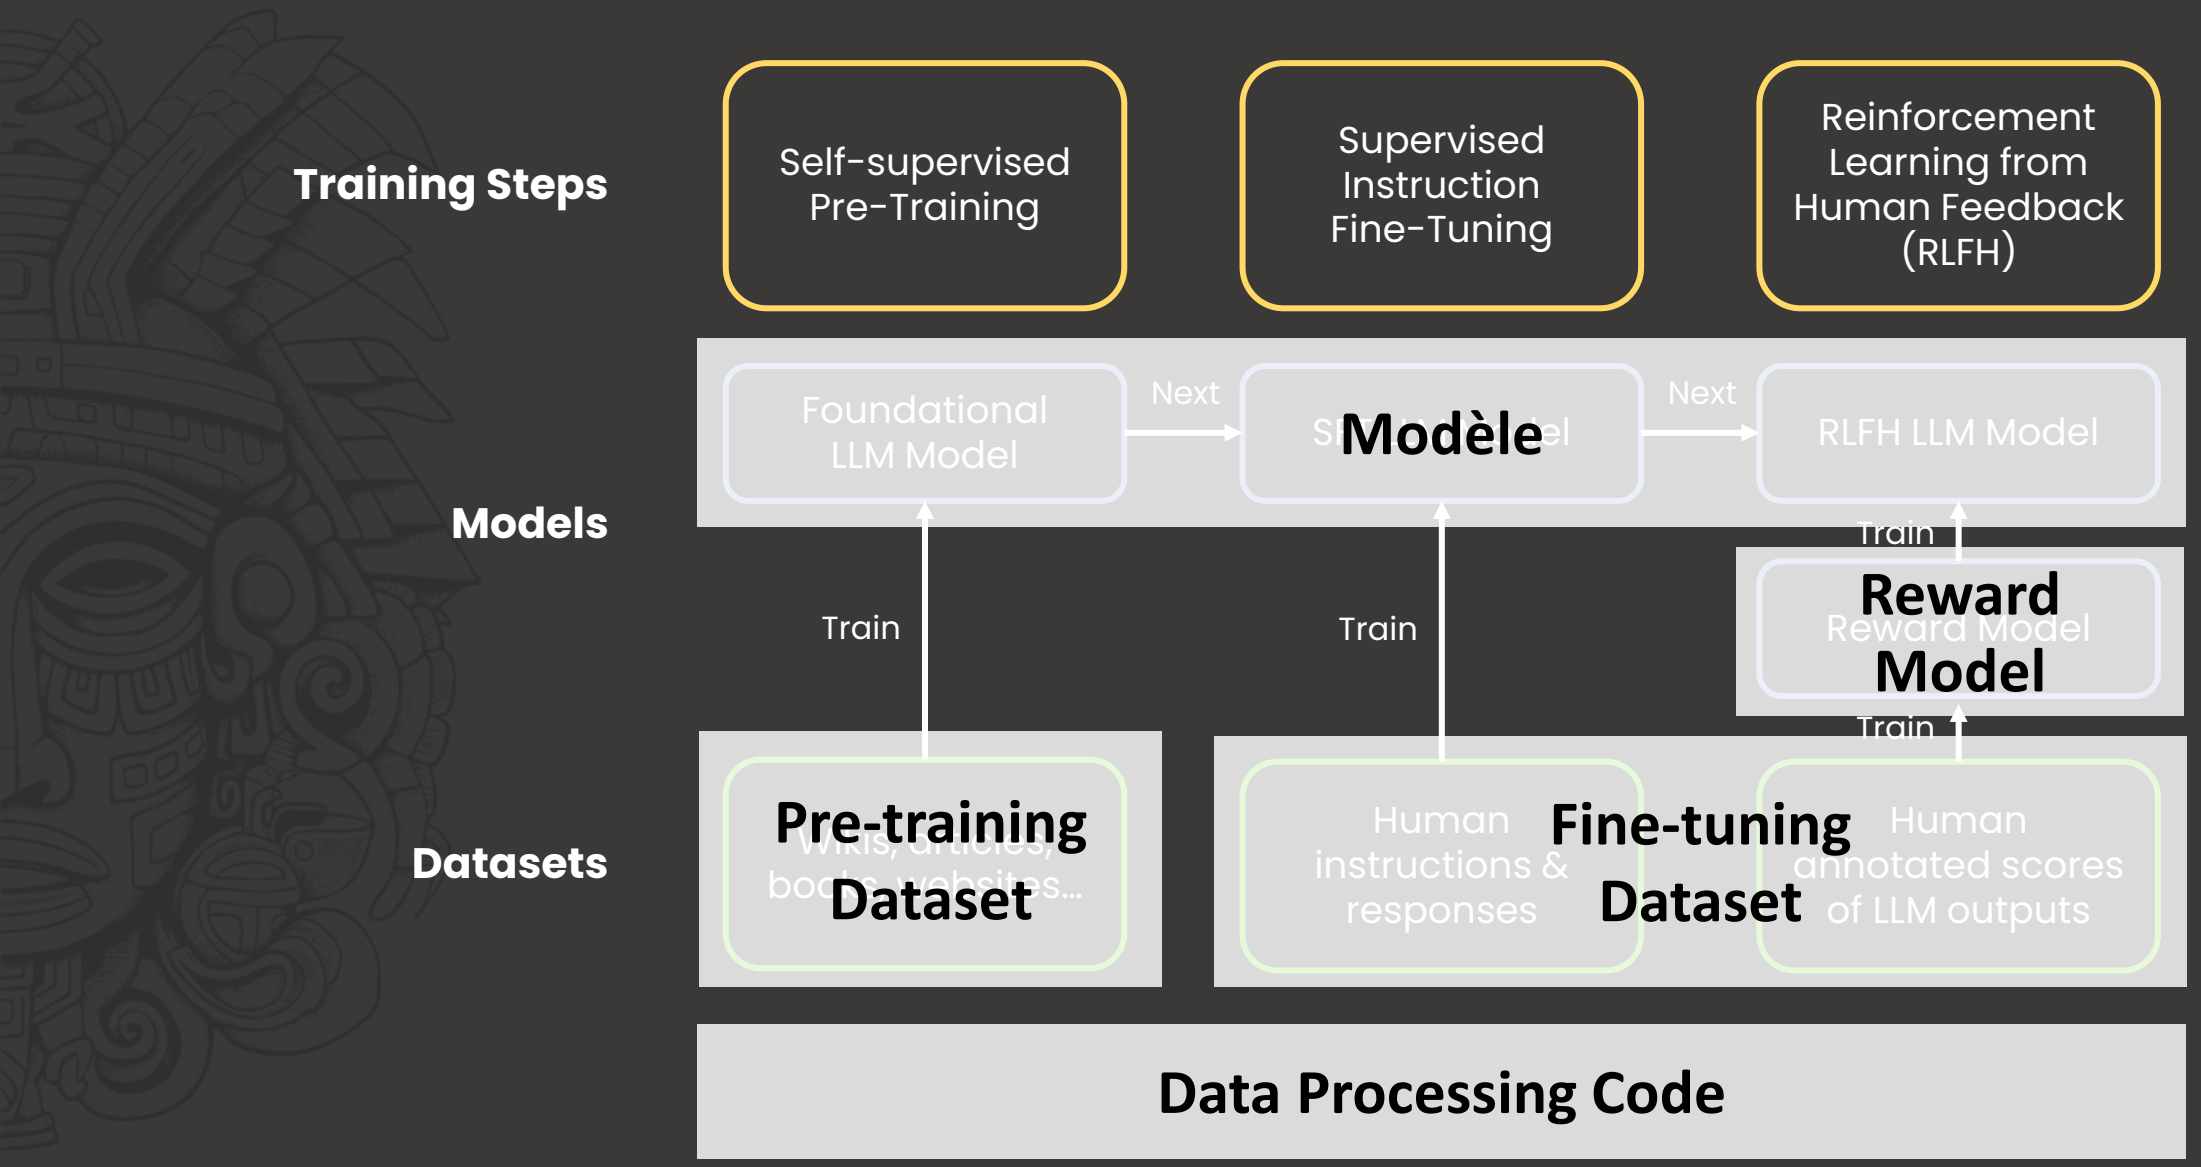
Small Language Models
Mobile, Agents et LAMs

La GenAI traverse son moment Linux



- Tout comme l'open source (et Internet), mais sur stéroïdes !
- Dynamique entre ouverture collaborative et propriété commerciale
- Besoin de clarté sur les licences

Définir l'ouverture d'un modèle



Définir l'ouverture d'un modèle

Score	Niveau	Description	Model (poids)	Pre-training Dataset	Fine-tuning Dataset	Reward model	Data Processing Code
0	**Fermé**	**Aucun accès** à des informations publiques, données ou actifs					
1	**Recherche publiée**	**Articles de recherche publiés** mais sans plus d'informations, de données ou d'actifs					
2	**Accès restreint**	Accès possible uniquement avec **accord spécial** (commercial, recherche...)					
3	**Ouvert avec limitations**	Accès et réutilisation possibles mais avec certaines **limitations d'utilisation**					
4	**Totalement ouvert**	Accès et réutilisation possibles **sans restriction d'utilisation** (ex. licence open source)					

Leader du marché : OpenAI

Écart par rapport à la vision originale de transparence et de recherche

OpenAI

Generative
Pre-trained
Transformer

GPT 1 & 2

Non lucratif (US)		
Composant	**Score**	**Niveau**
Modèle	4	Totalement ouvert
Dataset	1	Recherche publiée
Code	1	Recherche publiée

→

GPT-3.x, 4.x/o, Ox

0	Fermé

ChatGPT et o1

articles de recherche uniquement

Leader du marché : OpenAI

Écart par rapport à la vision originale de transparence et de recherche

GPT-1 & 2

GPT-3.x, 4.x/o, Ox

OpenAI

Non lucratif (US)		
Composant		
Modèle		
Dataset	1	Recherche publiée
Code	1	Recherche publiée

*You may not: […] Use **Output** to develop models that compete with OpenAI.*

0	Fermé

ChatGPT et o1

articles de recherche uniquement

Interdiction d'entrainer des LLMs commerciaux

Leader du marché : OpenAI

Écart par rapport à la vision originale de transparence et de recherche

GPT-1 & 2

GPT-3.x, 4.x/o, O

OpenAI

Code	1	Recherche publiée

rmé

PT et o1

articles de recherche uniquement

Open model feedback

We're planning to release our first open language model since GPT-2 in the coming months. We're excited to collaborate with developers, researchers, and the broader community to gather inputs and make this model as useful as possible.

Annonce récente d'OpenAI vers plus d'ouverture

Leader du marché : Google

De la recherche ouverte à une approche pragmatique

Google BERT

Entreprise (US)		
Composant	**Score**	**Niveau**
Modèle	4	Totalement ouvert
Dataset	2	Accès restreint
Code	4	Totalement ouvert

→

PaLM 2

Gemini

1	Recherche publiée
1	Recherche publiée
0	Fermé

→

Gemma

3	Ouvert avec limitations
1	Recherche publiée
4	Toolchain disponible

Leader du marché : Google

De la recherche ouverte à une approche pragmatique

Google BERT

PaLM 2

Gemma

Entre					
Composant					
Modèle				3	Ouvert avec limitations
Dataset		restreint	publiée	1	Recherche publiée
Code	4	Totalement ouvert	0	Fermé	4	Toolchain disponible

*You may **not use nor allow others to use** Gemma or Model Derivatives to: [illegals activities, unlicensed practices of profession, abuse, security bypass and promotion of hatred, abuse, violence, monitoring people without consent, misinformation/defamation, automate decisions concerning human rights and well-being, etc.]*

L'**IA responsable** contredit la définition de l'open source

D’autres acteurs majeurs

Rattrapent leur retard dans la ruée vers l’or de la GenAI

Créent leurs propres modèles (ouverts)












S'associent pour l'infrastructure (inférence et entrainement)

Leader du marché : Meta

Voyage vers l'ouverture

RoBERTa

Entreprise (US)		
Composant	**Score**	**Niveau**
Modèle	4	Totalement ouvert
Dataset	3	Ouvert avec limitations
Code	4	Totalement ouvert

→

LLaMA by Meta

3	Ouvert avec limitations
1	Recherche publiée
1	Recherche publiée



L'**IA responsable** contredit la définition de l'open source

Leader du marché : Meta

Voyage vers l'ouverture

Additional Commercial Terms. *If, on the Llama 2 version release date, the monthly active users of the products or services made available by or for Licensee, or Licensee's affiliates, is greater than 700 million monthly active users in the preceding calendar month, you must request a license from Meta, which Meta may grant to you in its sole discretion, and you are not authorized to exercise any of the rights under this Agreement unless or until Meta otherwise expressly grants you such rights.*

Code	4	Totalement ouvert		1	Recherche publiée



Restriction à l'utilisation

Licence pour les plateformes de +700 M utilisateurs

Leader du marché : Meta

Voyage vers l'ouverture

***Redistribution and Use**. If you distribute or make available the Llama Materials (or any derivative works thereof), or a product or service that uses any of them, including another AI model, you shall (A) provide a copy of this Agreement with any such Llama Materials; and (B) prominently display "Built with Meta Llama 3" on a related website, user interface, blogpost, about page, or product documentation. If you use the Llama Materials to create, train, fine tune, or otherwise improve an AI model, which is distributed or made available, you shall also include "Llama 3" at the beginning of any such AI model name.*

Code	4	Totalement ouvert

1	Recherche publiée

LLaMA 3 est **plus restrictif** en matière de redistribution et de réutilisation

Leader du marché : Meta

Voyage vers l'ouverture

Llama 4 Acceptable Use Policy

With respect to any multimodal models included in Llama 4, the rights granted under Section 1(a) of the Llama 4 Community License Agreement are ***not being granted to you if*** *you are an* ***individual*** *domiciled in, or a* ***company*** *with a principal place of business in, the* ***European Union****. This restriction does not apply to end users of a product or service that incorporates any such multimodal models.*

Code	4	Totalement ouvert
	1	Recherche publiée



LLaMA 4 est **interdit d'utilisation en Europe**

Progéniture de LLaMA : Alpaca et Vicuna

Modèles dérivés de LLaMA par des universités

Stanford Alpaca



VICUNA

Recherche (US)		
Composant	**Score**	**Niveau**
Modèle	3	Ouvert avec limitations
Pre-training Dataset	1	Recherche publiée
Fine-tuning Dataset	2	Recherche uniquement
Code	4	Licence Apache 2

Restrictions **héritées** de LLaMA 2 et OpenAI (ShareGPT)

Progéniture de LLaMA

Plus récemment : modèle dérivé de LLaMA par une entreprise



DEEP COGITO

Entreprise (US)		
Composant	**Score**	**Niveau**
Modèle	3	Ouvert avec limitations
Pre-training Dataset	1	Recherche publiée
Fine-tuning Dataset	0	Fermé
Code	0	Fermé



Restrictions **héritées** de LLaMA 3.2

LLMs fondamentaux collaboratifs

	Non lucratif (US)		Recherche (UAE)		Recherche (EU)		Recherche (US)		Consortium (FR)	
	EleutherAI GPT-J		Falcon		BLOOM		OpenLLaMa		Lucie	
Modèle	4	Accès et dérivation sans restriction	3	Ouvert avec limitations	3	Licence OpenRAIL	4	Accès et dérivation sans restriction	4	Accès et dérivation sans restriction
Dataset	3	Ouvert avec limitations	4	Accès et dérivation sans restriction	4	Totalement ouvert	4	Accès et dérivation sans restriction	4	Accès et dérivation sans restriction
Code	4	Totalement ouvert	1	Instructions générales	4	Totalement ouvert	3	Ouvert avec limitations	4	Totalement ouvert



Flou sur les datasets : se référer à la licence spécifique du sous-ensemble utilisé

Notion d'usage responsable

LLMs fondamentaux collaboratifs

	Non lucratif (US)		Recherche (UAE)		Recherche (EU)		Recherche (US)		Consortium (FR)	
	EleutherAI GPT-J		Falcon		BLOOM		OpenLLaMa		Lucie	
Modèle	4								4	Accès et dérivation sans restriction
Dataset	3								4	Accès et dérivation sans restriction
Code	4	Totalement ouvert	1	Instructions générales	4	Totalement ouvert	3	Ouvert avec limitations	4	Totalement ouvert

*This license is, in part, based on the Apache License Version 2.0, with a series of **modifications**. The contribution of the Apache License 2.0 to the framing of this document is acknowledged. Please **read this license carefully**, as it is different to other 'open access' licenses you may have encountered previously. Use of Falcon180B for hosted services may require a separate license.*

Licences open source modifiées

Autres LLMs open weights

	Entreprise (CN/FR)	
	DeepSeek / Mistral	
Modèle	4	Accès et dérivation sans restriction
Datasets	1	Recherche publiée
Code	4	Totalement ouvert

- **DeepSeek**
  - R1-zero entrainé sur une base v3
  - *Use restrictions* de v3 supprimées dans R1
  - Modèles distillés conservent leurs licences d'origine: Qwen 2.5, LLaMA 3.1/3.3
- **Mistral**
  - Versions Community VS Entreprise
  - *Sustainable openness* (codestral)

Autres LLMs open weights



- DeepSeek

Modèle		
Datasets		
Code	4	Totalement ouvert

MNPL - 3.2. Usage Limitation

- You shall only use the Mistral Models and Derivatives (whether or not created by Mistral AI) for testing, research, Personal, or evaluation purposes in Non-Production Environments;

- Subject to the foregoing, You shall not supply the Mistral Models or Derivatives in the course of a commercial activity, whether in return for payment or free of charge, in any medium or form, including but not limited to through a hosted or managed service (e.g. SaaS, cloud instances, etc.), or behind a software layer.

- Versions Community VS Entreprise
- *Sustainable openness* (codestral)



Émergence de *business models* mixtes (comme dans l'open source)

LLMs dérivés

	Entreprise (US)		Entreprise (US)		Entreprise (US)		Consortium (UAE/US)		Recherche (US)	
	Dolly		BLOOMChat		Zephyr		LLM360		OLMo-Instruct	
Modèle	4	Basé sur GPT-J	3	Basé sur BLOOM	4	Basé sur Mistral	4	Open source	4	Open source
Pre-training Dataset	3	Basé sur GPT-J	3	Basé sur BLOOM	0	Basé sur Mistral	4	RedPajama, Falcon, StarCoder	3	Dolma (ImpACT MR)
Fine-tuning Dataset	4	Accès et dérivation sans restriction	4	Dolly et LAION	2	Recherche uniquement (OpenAI)	3	Disponibles publiquement	3	Tülu 2 (IMPACT LR)
Reward model	0	Aucune information publique	0	Aucune information publique	3	Recherche et exemples de code	0	Aucune information publique	4	UltraFeedback (MIT)
Code	4	Open source	3	OpenRAIL	3	Exemples de code	4	Open source	4	Open source

Impact des modèles fondamentaux et des datasets

LLMs dérivés

	Dolly		BLOOMChat		Zephyr			olmo	
	Entreprise (US)		Entreprise (US)		Entreprise (US)		Consortium (UAE/US)	Recherche (US)	
Modèle									
Pre-train Dataset									
Fine-tuni Dataset									
Reward r									
Code	4	Open source	3	OpenRAIL	3	code	4	Open source	4	Open source

AI2 ImpACT Licenses - Restrictions

[…] a. military weapons purposes […]
b. purposes of military surveillance […]
c. purposes of generating or disseminating information or content […] without expressly and intelligibly disclaiming that the text is machine generated;
d. purposes of 'real time' remote biometric processing […]
e. fully automated decision-making without a human in the loop […] as spreading misinformation […]
f. purposes of the predictive administration of justice, law enforcement, immigration, or asylum processes, such as predicting an individual will commit fraud/crime

L'**IA responsable** contredit la définition de l'open source

LLMs dérivés

	Dolly		BLOOMChat		Zephyr		LLM360		OLMo-Instruct	
	Entreprise (US)		Entreprise (US)		Entreprise (US)		Consortium (UAE/US)		Recherche (US)	
Modèle	4	Basé sur GPT-J						pen source	4	Open source
Pre-training Dataset	3	Basé sur GPT-J						dPajama, lcon, arCoder	3	Dolma (ImpACT MR)
Fine-tuning Dataset	4	Accès et dérivation sans restriction						sponibles bliquement	3	Tülu 2 (IMPACT LR)
Reward model	0	Aucue information publique						ucue formation blique	4	UltraFeedback (MIT)
Code	4	Open source	3	OpenRAIL	3	Exemples de code	4	Open source	4	Open source

A suivre : Open-R1, OpenSeek





L'ouverture et la transparence favorisent l'**innovation** collective

Autres aspects du moment Linux

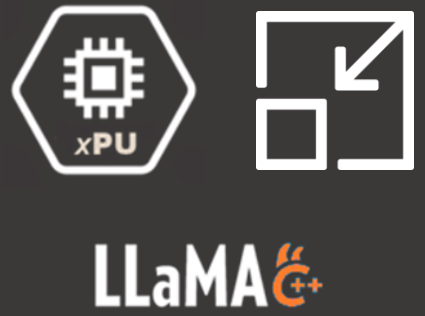
Démocratiser et décentraliser l'innovation

Outils collaboratifs et écosystèmes



Notebooks
Communautés
Nouveaux *Business Models*

Optimisations et infrastructure



SLM, Distillation
Quantization, Puces AI
Décentralisation

Outils et frameworks open source



Ne pas réinventer la roue
Standards interopérables (MCP, A2A)
Au-delà de Python

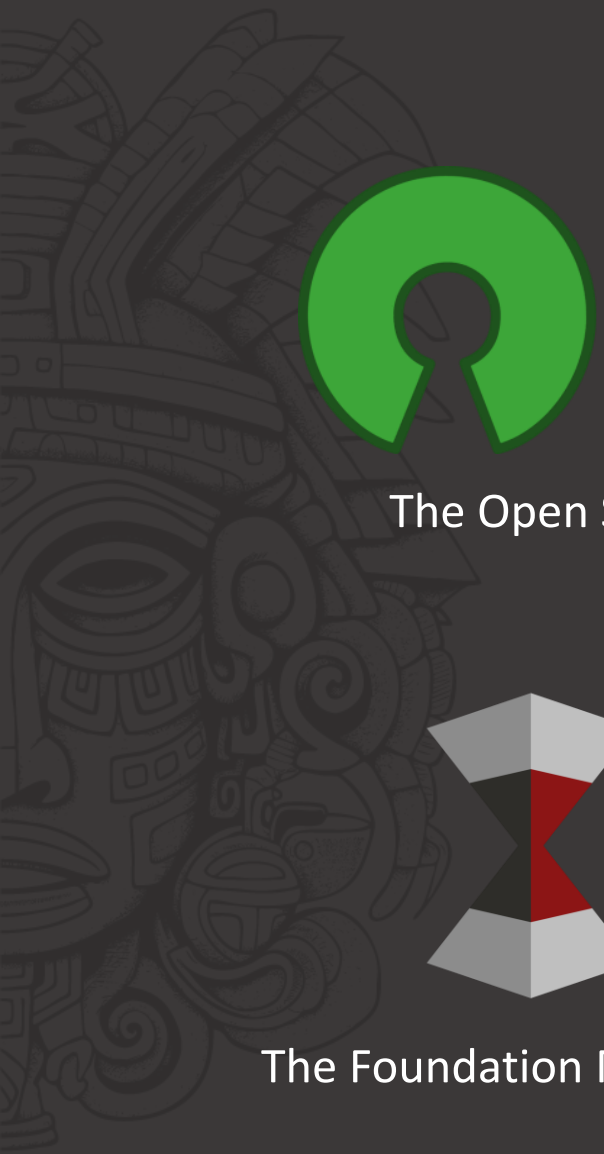
C’est la fin de notre exploration

- **APIs fermées → Open Weights → Free AI** (comme dans *freedom*)
  - Datasets et transitivité amont
  - Clauses de concurrence
  - Restrictions liées à l’IA responsable
- **Recherche ouverte → Marché concurrentiel → Écosystème coopétitif**
  - L'ouverture favorise la réutilisation et la collaboration
  - La collaboration entraîne la commoditisation et l'innovation

Moment → **Mouvement Linux !**



Initiatives d’évaluation de l’ouverture des LLMs



open source initiative®

The Open Source AI Definition

THE LINUX FOUNDATION

MODEL OPENNESS FRAMEWORK

Center for Research on Foundation Models

The Foundation Model Transparency Index

GOUVERNEMENT

Liberté
Égalité
Fraternité

Comparateur d'ouverture de modèles d'IAG


J’espère que vous y voyez
un peu plus clair



DEVOXX FRANCE 2025

Merci !

